Aula 01 - Revisão: regressão linear simples e principais conceitos

Universidade Federal do ABC (UFABC)
Curso: Bacharel em Ciências Econômicas
Disciplina: Econometria I
Período: 3º Quadrimestre de 2026
Turmas: Noturno (ESHC035-21)

Prof. Dr. Elson Rodrigo de Souza Santos

WhatsApp: 41 9 8454 0549
E-mail: elson.rodrigo@ufabc.edu.br ou elson129@gmail.com
Repositório: github.com/elsonr29
São Bernardo do Campo, November 14, 2026

Introdução

Tema:

Apresentar uma revisão dos principais conceitos que fundamentam a regressão linear simples, de modo a articular a consolidação desse conteúdo e promover o nivelamento dos alunos para as próximas aulas.

Objetivos e delimitação:

- ➜ A natureza da econometria aplicada em economia, com ênfase na interação entre os modelos teóricos formais e a identificação empírica;
- ➜ A importância da qualidade, do tratamento e da adequação dos dados;
- ➜ A regressão linear simples e seus principais conceitos, tais como as propriedades BLUE, os testes de hipóteses (valor-p para os testes t e F) e o coeficiente de determinação r-sq (R^2);
- ➜ A introdução as linguagens mais utilizados em econometria e economia (R e Python) e IDEs (RStudio e Spyker) e editores de código (VS Code e VS Codium).

Obs.: A aula adota como referência principal o manual Econometria Básica, de Gujarati (2005), abrangendo os capítulos 1 a 6. Como leitura complementar, utiliza os capítulos 1 e 2 de Wooldridge (2010).

Introdução

Organização da Aula:

1) Natureza da econometria aplicada em economia;
2) Base de dados;
3) Revisão: regressão linear simples;
4) Linguagens de programação, IDEs e editores de código

Importante!!!!: A abordagem possui caráter de revisão e nivelamento, partindo do pressuposto de que os alunos já estudaram esses temas nas aulas anteriores.

Contextualização: econometria aplicada

A econometria aplicada serve como meio para verificar a validade das hipóteses dos modelos econômicos e de sua estrutura formal, estando fortemente relacionada à teoria econômica. Além disso, temos:

- ➜ Fundamentos de teoria econômica (micro e macro), fortemente recomendados;
- ➜ Conhecimento prévio de métodos quantitativos e estatística;
- ➜ Noções básicas de programação e uso de linguagens de programação, IDEs e editores de código.

Obs.: Apesar de a econometria ser colocada como disciplina ou área em separado de outras, na realidade, acaba por ser uma aplicação empírica das demais áreas e disciplinas de economia, ao mesmo tempo em que passou a ser nativa nas disciplinas e áreas da economia.

Econometria vs. ciência de dados:

O diferencial da econometria e da economia na ciência de dados reside na fundamentação em modelos econômicos e em sua formalização. Portanto:

- ➜ Essa base teórica reduz o custo de aprendizado de novas técnicas, softwares e linguagens de programação;
- ➜ Facilidade em identificar o objetivo da análise e os caminhos para alcançar esse resultado;
- ➜ Melhor capacidade de modelar problemas e inferir relações causais e comportamentais.

Importante!!! O uso da técnica econométrica e da ciência de dados sem fundamentação teórica e conhecimento da literatura pode gerar resultados bizarros. Isto é, a inferência sugere uma relação causal, passa nos testes de robustez, mas não faz sentido teórico.

1) Natureza da econometria aplicada em economia

Ideia fundamental:

A ideia fundamental da econometria é testar os modelos econômicos, baseados em teoria e formalização, por meio da hipótese e da inferência causal, isto é, como uma variável x afeta a variável y. Assim, temos:

- ➜ **Não cai do céu!!!** O desenho do modelo econométrico, que indica como as variáveis estão relacionadas, não surge do nada, mas é resultado das indicações da teoria econômica e de inferências prévias;
- ➜ **Escolha da técnica:** a partir da hipótese e do modelo econométrico, é escolhida a técnica para realizar a inferência, não existindo, a priori, uma melhor ou pior;
- ➜ **Estratégia empírica:** indica como será realizada a inferência passo a passo, desde a construção da base de dados, os testes pré-estimação, a escolha do modelo e o modo como será utilizado, os principais resultados, os testes de robustez e o contrafactual.

Obs.: Para a construção de uma análise de econometria aplicada, é recomendado recorrer a trabalhos prévios similares, de modo que sirvam de orientação e inspiração.

Organização de um trabalho aplicado:

Na economia, seguimos uma estrutura base para trabalhos aplicados em econometria, que é válida para a economia em geral.

- ➜ Tema e objetivo, problema, hipótese e teoria e pode exigir a formalização do modelo;
- ➜ Base de dados que fundamenta o problema;
- ➜ Estratégia empírica com o modelo e a técnica econométrica, especificando o passo a passo;
- ➜ Principais resultados;
- ➜ Testes de robustez e contrafactual;
- ➜ Contribuições para a literatura.

Obs.: Em geral, esses elementos estão presentes nos *papers* de economia, não necessariamente nessa ordem, e apresentam pesos diferentes, dado o tipo de pesquisa, o periódico e a área específica.

Principais tipos de econometria:

A econometria apresenta áreas de concentração de famílias de modelos, as quais tendem a ser mais adequadas a determinada área e abordagem.

- ➜ **Dados em painel:** combinam as dimensões de corte transversal (*cross-section*) e temporal ao acompanhar as mesmas unidades de análise (indivíduos, firmas, regiões ou países) ao longo do tempo. Permitem controlar a heterogeneidade não observada e estudar dinâmicas de ajuste;
- ➜ **Séries temporais:** analisam a evolução de uma ou mais variáveis ordenadas cronologicamente em intervalos regulares. Focam na dependência temporal, em tendências, ciclos, propagação de choques e previsões, com ampla aplicação em macroeconomia e finanças;
- ➜ **Econometria espacial:** incorpora a localização geográfica e as relações de vizinhança ou distância entre unidades econômicas na especificação empírica. Permite mensurar efeitos de transbordamento (*spillovers*), dependência e heterogeneidade espacial entre regiões.

Obs.: Não são áreas de concentração segregadas. Na realidade, elas tendem a interagir. Por exemplo, é comum o uso de dados em painel com séries temporais na inferência sobre o comportamento de países e regiões, firmas e famílias.

2) Qualidade e tratamento dos dados

Delimitação:

Os dados são insumos fundamentais para economia e econometria. Assim, temos como tipos de dados:

- ➜ **Corte transversal**: analisa diversas unidades (indivíduos, firmas ou regiões) em um único ponto no tempo, capturando diferenças estruturais entre os agentes;
- ➜ **Séries temporais**: acompanha uma ou mais variáveis ordenadas cronologicamente ao longo do tempo, permitindo analisar dinâmicas de curto e longo prazo;
- ➜ **Painel**: combina corte transversal e séries temporais ao observar as mesmas unidades ao longo do tempo, permitindo controlar a heterogeneidade não observada.

Obs.: A presença do tempo em dados em painel não significa que serão utilizadas técnicas de séries temporais. Na realidade, são estágios diferentes da análise. Primeiro, escolhemos a base de dados e, depois, o modelo e a abordagem mais adequados ao objetivo.

2) Qualidade e tratamento dos dados

Base de dados:

Geralmente, as bases de dados para trabalhos aplicados não estão prontas. Dessa forma, é necessário extrair dados de outras fontes e fazer a compilação, a limpeza e o tratamento para obter tal base de dados para a aplicação da econometria.

- ➜ **Fontes livres**: oriundas de instituições de pesquisa e órgãos públicos que disponibilizam bases de dados gratuitamente. Por exemplo, IBGE, IPEADATA, BACEN, Secretária do Tesouro Nacional e SICONFI, CVM e B3, FMI e Banco Mundial;
- ➜ **Fontes privadas**: oriundas de empresas, consultorias ou provedores comerciais, geralmente obtidas mediante assinatura ou licença institucional, tais como Economatica, Bloomberg, Refinitiv e Quantum Axis.
- ➜ **APIs**: acesso direto a bases de dados por meio de protocolos de programação, permitindo a extração e a atualização rápida das informações, em particular, por meio do R e do Python.

Importante!!!: As APIs aceleram a obtenção de dados primários, tais como a API do IPEADATA, a do Tesouro Nacional, para finanças públicas, a do BACEN e CVM, para dados bancários e financeiros.

2) Qualidade e tratamento dos dados

Compilação, limpeza e tratamento:

A partir dos dados primários, é necessário preparar a base para o uso nos modelos econométricos.

- ➜ **Compilação**: unificação e integração de dados provenientes de diferentes fontes, formatos e periodicidades em uma única base estruturada, compatibilizando chaves de identificação (como códigos territoriais, identificadores de agentes ou datas);
- ➜ **Limpeza**: identificação e correção de inconsistências nos dados brutos, tais como valores ausentes (*missing values*), registros duplicados, erros de digitação, padronização de formatos e verificação de valores atípicos (*outliers*);
- ➜ **Tratamento**: transformação e adequação das variáveis para a estimação econométrica, incluindo o deflacionamento de séries nominais, a aplicação de logaritmos, o cálculo de taxas de variação e a criação de variáveis *dummy* ou defasagens.

Importante!!!: No trabalho, é essencial que estejam muito claras as fontes, a estruturação da base de dados e como foram feitos a limpeza e o tratamento para o uso nos modelos. Essa é uma parte que contribui para a robustez e confiabilidade.

2) Qualidade e tratamento dos dados

Atenção e cuidados:

A base de dados influencia o modelo econométrico e a estratégia empírica do trabalho, alterando os resultados em termos de identificação, robustez e fundamentação. Portanto, cabe considerar:

- ➜ **Não experimental**: a economia é uma ciência social cujos dados podem conter erros de medida, por omissão ou execução, que tendem a ser sistemáticos e a gerar distorções nas séries. Por exemplo, como mensurar a satisfação, a riqueza familiar ou os dados orçamentários;
- ➜ **Imprecisões e arredondamentos**: a pesquisa de dados exige uma metodologia para lidar com problemas de mensuração, a qual pode implicar viés e problemas não explícitos, incluindo a dificuldade de comparação entre períodos e indivíduos. Por exemplo, como medir a inflação ao longo do tempo, o produto e a renda *per capita*;
- ➜ **Viés amostral**: a amostra não reflete a população por ser mal formulada. Por exemplo, estimar determinantes salariais considerando apenas trabalhadores do setor formal ou avaliar o consumo das famílias a partir de amostras restritas a grandes centros urbanos.

Obs.: A base de dados pode mudar o resultado!!!! Isto é, pode contradizer a teoria, outros trabalhos empíricos similares e fornecer resultados espúrios.

3) Revisão: regressão linear simples

Introdução:

A regressão linear simples é o primeiro passo para compreender a estimação, a inferência estatística e os fundamentos da identificação causal entre duas variáveis. Para isso, adotamos a abordagem linear e frequentista.

- ➜ **Duas variáveis**: temos a variável independente (x) e a dependente (y). A ideia é identificar como x causa y;
- ➜ **Mínimos Quadrados Ordinários (ou OLS)**: utilizamos o MQO como base para estimar a regressão de duas variáveis, estabelecendo as propriedades do estimador BLUE e as hipóteses de normalidade;
- ➜ **Dados *cross-section***: utilizamos a base de dados mais simples possível, excluindo as dimensões de tempo e de grupos.

Importante!!!: É o ponto de partida. Em seguida, é possível compreender a regressão múltipla, a introdução de elementos como controles e *dummies*, os testes t e F e o ajustamento pelo R^2. Dessa forma, passamos a trabalhar os diferentes modelos e abordagens.

Frequentista vs. bayesiana vs. *machine learning*:

Os manuais básicos e as disciplinas introdutórias de econometria adotam o modelo linear e frequentista. No entanto, existem também as abordagens bayesiana e de *machine learning*.

- ➜ **Linear frequentista**: temos parâmetros populacionais tratados como constantes fixas, com estimação e inferência baseadas em distribuições amostrais e formas funcionais lineares;
- ➜ **Bayesiana**: utiliza o teorema de Bayes para combinar informações prévias (*priors*) aos dados observados, tratando os parâmetros como variáveis aleatórias;
- ➜ ***Machine Learning* (ML)**: utiliza algoritmos flexíveis para maximizar a acurácia preditiva fora da amostra em bases complexas e de alta dimensionalidade.

Obs: Não significa que um seja superior ao outro, mas sim que são adequados para responder a problemas diferentes. Entre as técnicas e na escolha do modelo, **utilize a navalha de Ockham**, que preconiza escolher a mais simples que resolva o problema.

Ideia base: modelo teórico

Partimos de um modelo simples que relaciona a variável independente (x) e a dependente (y). A justificativa teórica é que y é uma função de x. Assim, temos:

$$y = f(x) \tag{1}$$

Essa função é baseada na teoria econômica e na formalização. Por exemplo, na microeconomia e em um mercado em concorrência perfeita, consideramos que o preço (p) é a variável independente e a quantidade (q) é a dependente. Para o indivíduo i, podemos reescrever essa relação como:

$$q_i = f(p_i), \quad \text{para } i = 1, 2, \ldots, n \tag{2}$$

Resultado: Portanto, segundo o modelo, o preço (p) é um sinal que afeta a decisão sobre a quantidade de consumo (q_i^d) das famílias ou de produção (q_i^s) das firmas. Note que cada indivíduo i deve ter uma resposta própria ao preço.

Ideia base: modelo econométrico

Considerando o modelo de regressão linear simples estimado por OLS, temos:

$$y_i = \beta_0 + \beta_1 x_i + u_i \tag{3}$$

Onde:

- y_i: variável dependente (ou explicada) para a observação i;
- x_i: variável independente (ou explicativa) para a observação i;
- β_0 e β_1: parâmetros populacionais (intercepto e coeficiente angular, respectivamente);
- u_i: termo de erro aleatório, que incorpora os demais fatores não observados que afetam y_i.

Obs: Adotamos dados em corte transversal (*cross-section*), isto é, desconsideramos a dimensão temporal e os grupos de indivíduos. Essa é, portanto, a configuração mais simples possível para a base de dados e modelo.

Ideia base: modelo econométrico

Reescrevemos (3) considerando o problema das curvas de demanda e de oferta:

$$q_i^d = \beta_0^d + \beta_1^d p_i + u_i^d \qquad \text{(demanda das famílias)} \tag{4}$$

$$q_i^s = \beta_0^s + \beta_1^s p_i + u_i^s \qquad \text{(oferta das firmas)} \tag{5}$$

Predição da teoria:

- ➜ O preço (p_i) afeta as decisões de consumo e de produção, respectivamente, da família (q_i^d) e da firma (q_i^s);
- ➜ Para as famílias, há uma **relação negativa** (maior preço, menor consumo);
- ➜ Para as firmas, há uma **relação positiva** (maior preço, maior produção).

Obs: Essa é uma relação conhecida e consolidada. Portanto, a teoria deve ser coerente com o resultado empírico. Caso não seja, a divergência merece maior atenção e deve ser investigada.

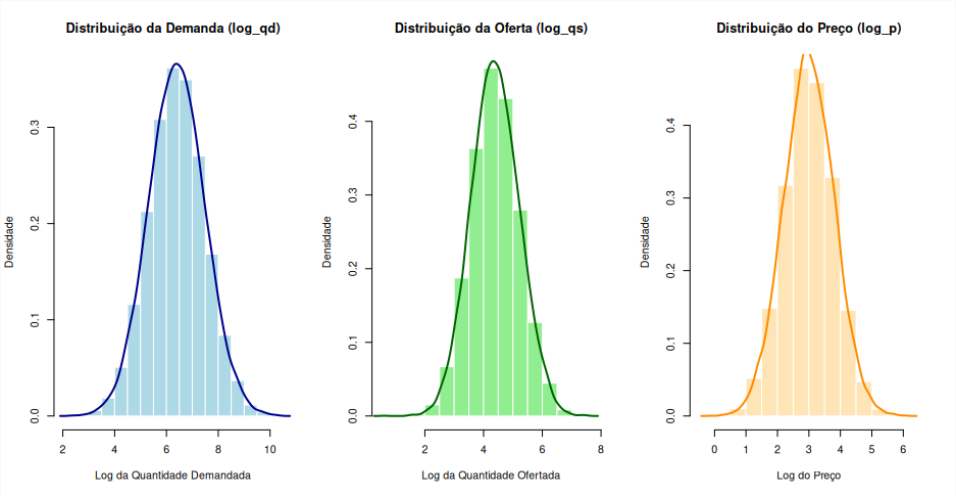
Dados e indicações:

Para ilustrar a dinâmica da regressão simples por OLS, simulamos 10 mil observações no R:

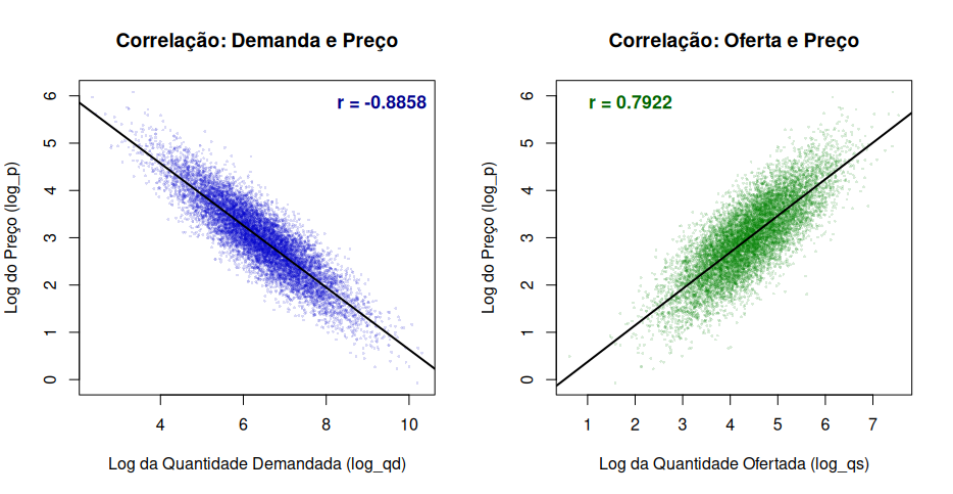
- ➜ O preço (p_i) afeta as decisões de consumo e de produção, respectivamente, da família (q_i^d) e da firma (q_i^s);
- ➜ Para as famílias, há uma **relação negativa** (maior preço, menor consumo);

Obs: Recorremos à simulação de dados sintéticos devido à sua praticidade. Adicionalmente, aplicamos a transformação logarítmica às variáveis para linearizar as relações funcionais. Essa é uma estratégia comum na economia, pois preserva a linearidade nos parâmetros exigida pela regressão linear e permite estimar diretamente a elasticidade por meio do coeficiente β_1.

Distribuição: quantidade e preço



Correlação: demanda e oferta



Resultados: demanda

```
> modelo_oferta <- lm(log_qs ~ log_p, data = dados)
>
> # Resultados
> summary(modelo_demanda)

Call:
lm(formula = log_qd ~ log_p, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-1.7413 -0.3345 -0.0037  0.3404  1.8848

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.984130   0.019450   513.3   <2e-16 ***
log_p       -1.196225   0.006269  -190.8   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.5008 on 9998 degrees of freedom
Multiple R-squared:  0.7846,    Adjusted R-squared:  0.7846
F-statistic: 3.641e+04 on 1 and 9998 DF,  p-value: < 2.2e-16
```

Resultados: oferta

```
> summary(modelo_oferta)

Call:
lm(formula = log_qs ~ log_p, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-1.7418 -0.3414 -0.0036  0.3454  2.1799

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 1.958896   0.019425   100.8   <2e-16 ***
log_p       0.812526   0.006261   129.8   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.5002 on 9998 degrees of freedom
Multiple R-squared:  0.6275,    Adjusted R-squared:  0.6275
F-statistic: 1.684e+04 on 1 and 9998 DF,  p-value: < 2.2e-16
```

Principais informações

Os resultados das regressões para demanda e oferta trazem informações-chave:

- ➜ β_1^d **e** β_1^s: indicam a variação média da quantidade (q) em resposta à variação de uma unidade no preço (p);
- ➜ **Estatística** t **e** p**-valor**: avaliam a significância estatística individual de cada parâmetro ($H_0 : \beta_j = 0$). Por convenção, adotamos *10% (0,10), **5% (0,05) e ***1% (0,01) como níveis de significância;
- ➜ **Teste** F: avalia a significância estatística conjunta dos regressores (o poder explicativo global do modelo), conforme o seu p-valor;
- ➜ R^2 **(coeficiente de determinação)**: indica a proporção da variação total de y explicada pela variável independente (x).

Importante!!!: O coeficiente de determinação varia de 0 a 1 ($0 \leq R^2 \leq 1$). Esse intervalo não implica que uma regressão com $R^2 = 1$ seja superior. Ao contrário, um ajuste perfeito pode indicar problemas graves nos dados e na especificação do modelo.

Principais resultados:

A partir das regressões e das informações-chave, podemos corroborar a teoria com base nas evidências empíricas. Isto é, os resultados foram coerentes com o esperado para as curvas de demanda e de oferta.

- ➜ **Curva de demanda**: confirma que o coeficiente β_1^d é negativo e estatisticamente significativo;
- ➜ **Curva de oferta**: confirma que o coeficiente β_1^s é positivo e estatisticamente significativo.

A coerência entre teoria e evidência é esperada. A informação relevante é a sensibilidade indicada pelo parâmetro β_1^d (que, devido ao uso de logaritmos, representa a elasticidade), além de sua significância estatística, avaliada pelo *p*-valor.

Importante!!!: Se o resultado for incoerente com a teoria e com outros trabalhos empíricos, há duas hipóteses possíveis: *i*) problemas na base de dados, na metodologia ou na interpretação dos resultados; *ii*) a descoberta de uma nova relação para um caso específico. Ambos os casos exigem investigação.

Robustez:

A robustez dos resultados significa que eles devem ser solidamente fundamentados. Para isso, precisam ser validados em testes adicionais e respeitar as hipóteses do modelo. No caso do OLS:

- ➜ **Estimador BLUE**: corresponde ao Melhor Estimador Linear Não Viesado (*Best Linear Unbiased Estimator*), propriedade garantida quando o modelo atende às hipóteses de Gauss-Markov;
- ➜ **Erros estocásticos**: condições exigidas para o termo de erro (u_i), incluindo média condicional nula ($E(u_i \mid x_i) = 0$), homoscedasticidade ($\text{Var}(u_i \mid x_i) = \sigma^2$) e ausência de autocorrelação (além de normalidade para inferência em amostras finitas).

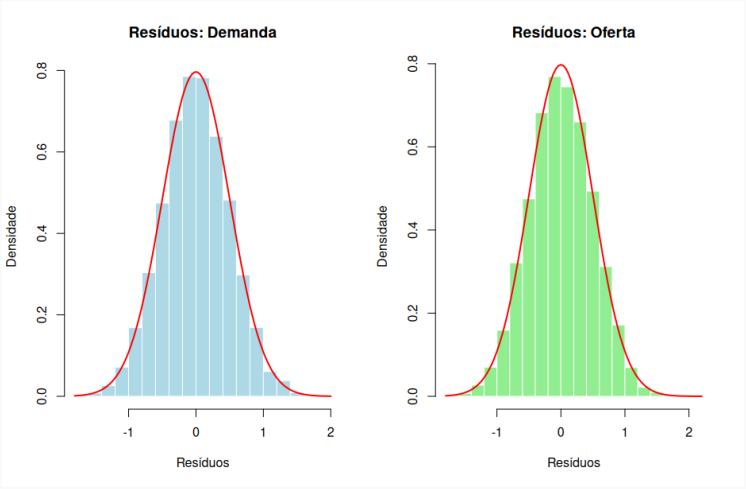
Importante!!!: Na realidade do uso da econometria aplicada, o modelo passar nos testes de robustez pode ser bem complexo. Por isso, exige uma estratégia empírica bem fundamentada. Além disso, a escolha do tipo de modelo e abordagem adequado. Portanto, o OLS é o ponto de partida, serve de abordagem inicial, mas possui versões mais sofisticadas. Além disso, testes adicionais e outros modelos para resolvem problemas que não abordados no OLS.

Hipóteses de Gauss-Markov:

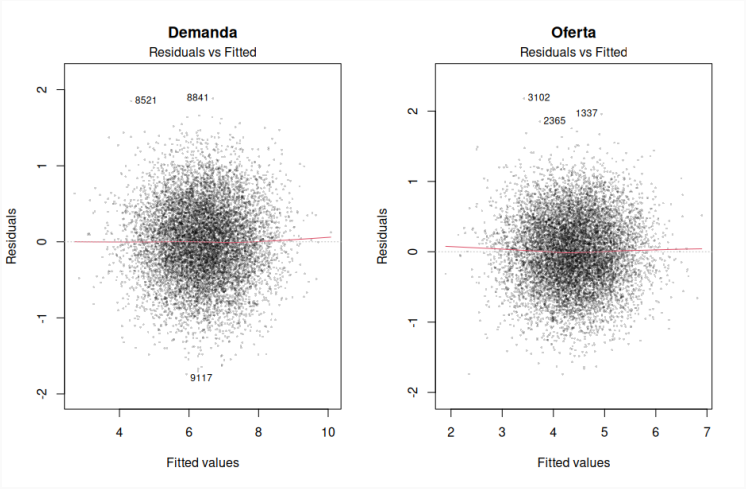
- **Linearidade nos parâmetros**: o modelo populacional é linear nos coeficientes ($y_i = \beta_0 + \beta_1 x_i + u_i$);
- **Amostragem aleatória**: as observações constituem uma amostra aleatória extraída da população (garantindo independência entre os erros);
- **Variação amostral em x_i**: a variável explicativa não é constante na amostra (no caso múltiplo, exige ausência de colinearidade perfeita);
- **Média condicional nula**: o termo de erro possui valor esperado zero dado x_i, ou seja, $E(u_i \mid x_i) = 0$ (exogeneidade);
- **Homoscedasticidade**: a variância do erro é constante para qualquer valor de x_i, isto é, $\text{Var}(u_i \mid x_i) = \sigma^2$.

Obs.: É uma revisão dos conceitos básicos de regressão e do OLS.

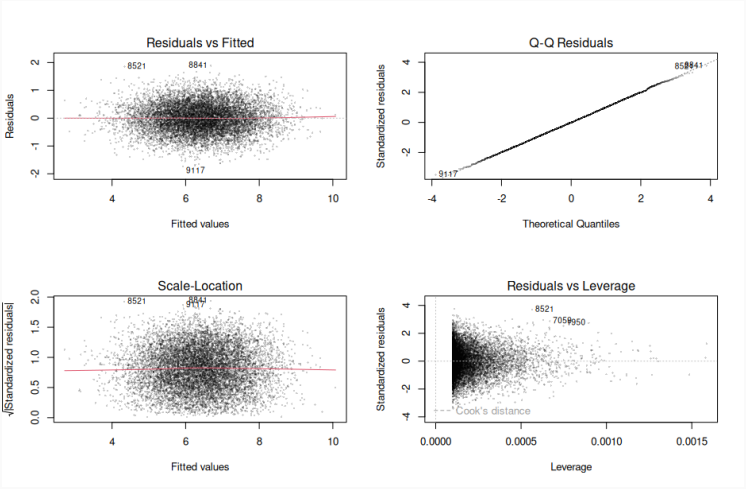
Normalidade dos erros:



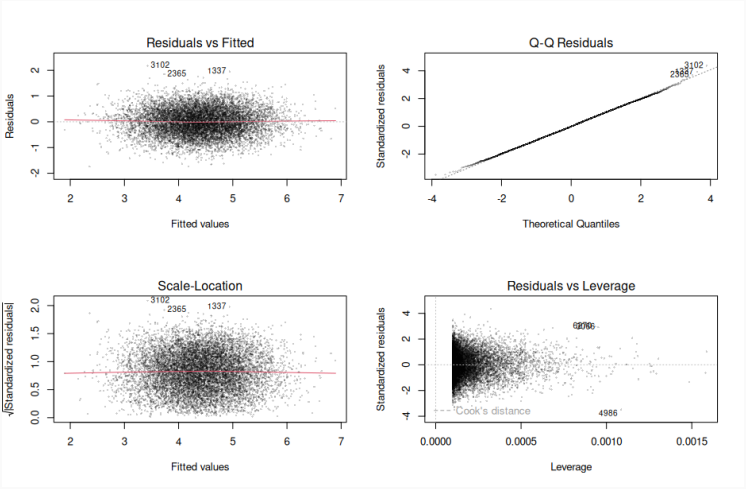
Normalidade dos erros:



Normalidade dos erros: demanda



Normalidade dos erros: oferta



4) Linguagens de programação, IDEs e editores de código

Definição:

As linguagens de programação, IDEs e softwares são peças fundamentais para a economia aplicada por meio da econometria, devido aos seguintes fatores:

- ➜ **Organização, limpeza e tratamento das bases de dados**: em particular, grandes conjuntos de dados apresentam limitações quando manipulados em softwares de planilhas (Excel, do Microsoft Office, ou Calc, do LibreOffice);
- ➜ **Aplicação dos modelos econométricos**: dispensa o cálculo manual, utilizando softwares, pacotes ou rotinas de programação específicas para gerar as estimativas do modelo, bem como os testes e os gráficos pertinentes;
- ➜ **Roteiro de análise**: reduz o custo de implementar todas as etapas da pesquisa, abrangendo o tratamento da base de dados, as estatísticas descritivas, os testes pré-estimação, os resultados principais, os testes de robustez e as representações gráficas.

Importante!!!: A economia computacional não substitui o conhecimento em teoria econômica, em formalização e, principalmente, em econometria. Sem isso, a economia computacional se torna uma alegoria.

Linguagens de programação vs. softwares:

A linguagem de programação e os softwares são coisas diferentes. Apesar de a distinção ser confusa, na medida em que dizem respeito a como operacionalizar os modelos econométricos:

- ➜ **Linguagem de programação**: fundamenta como escrever os modelos econométricos e proceder às etapas de análises pertinentes. As mais usadas na economia são o R e o Python, que são ambientes abertos e livres para contribuições;
- ➜ **Softwares**: consistem em programas mais específicos de análise e lógica interna. Na economia, os softwares mais utilizados são o Stata e o EViews. Ambos são softwares proprietários, de pacote fechado, o que limita as contribuições e o uso, devido ao emprego da interface gráfica;

Importante!!!: Observe que a distinção é sutil. No fundo, ambos usam uma linguagem base em C. A diferença está na interface e na liberdade de como o usuário pode utilizá-los.

Linguagens de programação vs. softwares:

A linguagem de programação e os softwares são coisas diferentes. Apesar de a distinção ser confusa, na medida em que dizem respeito a como operacionalizar os modelos econométricos:

- ➜ **Linguagem de programação**: fundamenta como escrever os modelos econométricos e proceder às etapas de análises pertinentes. As mais usadas na economia são o R e o Python, que são ambientes abertos e livres para contribuições;
- ➜ **Softwares**: consistem em programas mais específicos de análise e lógica interna. Na economia, os softwares mais utilizados são o Stata e o EViews. Ambos são softwares proprietários, de pacote fechado, o que limita as contribuições e o uso, devido ao emprego da interface gráfica;

Importante!!!: Observe que a distinção é sutil. No fundo, ambos usam uma linguagem base em C. A diferença está na interface e na liberdade de como o usuário pode utilizá-los.

Linguagens de programação livres:

As linguagens de programação livres (R e Python) são atraentes, na medida em que são simples para não programadores, ao mesmo tempo em que conciliam a liberdade de modificação, a criação de pacotes e a rede de colaboração descentralizada.

- ➜ **R**: linguagem de programação e ambiente de código aberto voltado especificamente para computação estatística, análise de dados e visualização gráfica. Na econometria, reúne um ecossistema consolidado de pacotes especializados (via CRAN) para estimação de modelos, inferência causal e produção de gráficos e relatórios científicos;
- ➜ **Python**: linguagem de programação de propósito geral e de código aberto, caracterizada pela sintaxe legível e pela alta versatilidade. Na economia e na ciência de dados, integra o tratamento de grandes bases e a estimação econométrica (por meio de bibliotecas como *pandas*, *statsmodels* e *linearmodels*) a rotinas de automação, raspagem de dados e aprendizado de máquina (*machine learning*).

Importante!!!: Óbvio que não são os únicos, mas os mais utilizados. Temos alternativas como Julia, ainda que em desenvolvimento

IDEs e editores de código:

O R e Python tendem a não serem utilizados diretamente. Apesar de poderem. É comum e recomendado usar IDEs e editores de código:

- ➜ **IDE (*Integrated Development Environment*)**: ambiente de desenvolvimento integrado que reúne, em uma única interface gráfica, as ferramentas essenciais para escrever, testar e executar códigos. Para o R, temos o RStudio e, para o Python, o Spyder, além do Jupyter (JupyterLab e Jupyter Notebook). No entanto, RStudio pode usar Python, Mark Down e outras linguagens;
- ➜ **Editores de código (VS Code e VS Codium)**: programas leves voltados à escrita e à edição de códigos em múltiplas linguagens, que incorporam funcionalidades de IDE (terminal integrado, depuração, execução de scripts em R e Python e suporte a cadernos computacionais) por meio de extensões. O **VS Code** é distribuído pela Microsoft com componentes proprietários e telemetria, enquanto o **VS Codium** corresponde à compilação totalmente livre e de código aberto.

Importante!!!: Existem alternativas como Anaconda para computação científica e análise de dados em R e Python. O R e Python podem ser usados no Google Colab.

Código e os pacotes:

O R e o Python, usados a partir de IDEs e editores de código, exigem a escrita de códigos e permitem o uso de pacotes.

- ➜ **Código**: conjunto de instruções escritas conforme as regras de sintaxe de uma linguagem de programação (como R ou Python) para execução de tarefas, incluindo a importação de bases de dados, o tratamento de variáveis, a estimação de modelos econométricos e a geração de gráficos. O registro dessas instruções em arquivos de script e documentado;
- ➜ **Pacotes**: conjuntos de funções, rotinas e algoritmos pré-programados que expandem as capacidades nativas de uma linguagem. Desenvolvidos e compartilhados pela comunidade científica, reúnem ferramentas como *fixest* e *plm* no R, ou *statsmodels* e *linearmodels* no Python, permitindo aplicar modelos econométricos sem a necessidade de programar a partir do zero.

Importante!!!: Qualquer pessoa pode desenvolver um pacote. É comum que os pacotes sejam de inovações em modelos econométricos e bases de dados.

Uso da Inteligência artificial (IA):

A Inteligência Artificial (IA) passou a ser um instrumento básico para trabalhar com modelos empíricos, programação e códigos em R e Python, em particular por meio de modelos como Claude, ChatGPT e Gemini. Essas ferramentas facilitam o fluxo de trabalho, aceleram a curva de aprendizado e auxiliam na resolução de problemas. Para uso das IAs:

- ➜ **Perguntas diretas**: formular questionamentos objetivos sobre pacotes, trechos de código e resolução de problemas, pois isso evita alucinações e perda de foco, ainda que essas falhas possam ocorrer e indicar caminhos equivocados;
- ➜ **Ponderação na interpretação**: as IAs podem alucinar a partir da pergunta e do problema apresentados, incluindo a alteração de parâmetros e erros teóricos no modelo, mesmo quando não solicitados;
- ➜ **Revisão crítica**: as respostas teóricas e os códigos em econometria devem passar por revisão rigorosa, pois as IAs podem ser muito convincentes ao indicar caminhos equivocados e justificar erros.

Importante!!!: A IA não substitui o conhecimento teórico e visão crítica humana.

Revisão

Principais pontos:

- ➜ Partimos da estrutura básica de um artigo ou estudo em economia que utiliza econometria, demonstrando a interação entre modelo econômico, formalização teórica e análise empírica;
- ➜ Discutimos brevemente a importância dos dados nos modelos, destacando que a qualidade e o tratamento das informações são fundamentais para a robustez, a escolha do modelo e a estratégia econométrica;
- ➜ Realizamos uma breve revisão dos conceitos da regressão linear simples, com ênfase nas propriedades do estimador BLUE, nos testes de hipóteses, no valor-p das estatísticas t e F e no significado do coeficiente de determinação (R^2);
- ➜ Apresentamos uma breve introdução linguagens de programação e IDEs mais utilizados em economia, com foco nas ferramentas livres.

Próxima aula: A partir dessa revisão e desse nivelamento, os alunos estarão preparados para o estudo da regressão múltipla na próxima aula.

Referências

Principal:

Gujarati, D. (2006). Econometria básica (4ª ed.). Campus. Cap. 1 - 6.

Wooldridge, J. (2010). Introdução à econometria: Uma abordagem moderna (4ª ed.). Thomson Pioneira. Cap. 1 e 2.

Referências:

Economia Computacional - Python e R:

Coutinho, D. (2020). R: Uma introdução para economistas.
https://danmrc.github.io/R-para-Economistas/

Sargent, T. J., Stachurski, J. (2024). A first course in quantitative economics with Python.
QuantEcon. Disponível em: ¡ https://intro.quantecon.org/intro.html ¿ . Acesso em: 02 junho de 2026.

Sargent, T. J., Stachurski, J. (2024). Python programming for economics and finance. QuantEcon.
https://python-programming.quantecon.org/

Shikida, C. D., Fernandez, R. N. (2016). Notas introdutórias em econometria aplicada usando
R/RStudio. Universidade Federal de Pelotas.
http://wp.ufpel.edu.br/cdshikida/files/2016/10/MinicursoEconometriaRStudio.pdf

Ventura, V. (2024). Guia de econometria aplicada com Python. Universidade Federal de Alagoas.
https://viniciusventura.com.br/projetos/monitoria-econometria